



**UNIVERSIDAD
DEL PACÍFICO**

Economía

Facultad de Economía y Finanzas

Un caso: créditos y venta en el Perú

Díaz Tejada, Luciano

Lima, abril del 2025

I. Análisis estadístico y caracterización económica de una serie de créditos mensuales

Para realizar un análisis adecuado de la serie mensual de créditos, se aplicó una transformación logarítmica con el fin de trabajar con tasas de crecimiento relativas. Como primer paso de identificación del enfoque Box-Jenkins, se examinó gráficamente la serie transformada (\ln_cred) y su correlograma (ver Anexo 1 y 2). Visualmente, la serie muestra un crecimiento sostenido entre 2000 y 2020, con tres fases diferenciadas: una ligera caída inicial (2000–2002), una expansión acelerada hasta 2008–2009, y una trayectoria más moderada desde entonces. No se observan caídas abruptas, lo que sugiere una evolución estable. El correlograma evidencia una alta persistencia, con autocorrelaciones elevadas incluso en rezagos largos. La función de autocorrelación parcial (FAP) muestra un único pico significativo en el primer rezago, lo cual sugiere un comportamiento tipo $AR(1)$, posiblemente con raíz unitaria (ver Anexo 3). Se aplicó la prueba de Dickey-Fuller aumentada (ADF) para verificar la presencia de raíz unitaria. El resultado (estadístico $ADF = -1.14$, $p = 0.9186$) confirmó que la serie no es estacionaria. Además, ni la constante ($p = 0.19$) ni la tendencia ($p = 0.34$) fueron significativas, por lo que se reestimó el test bajo especificaciones más parsimoniosas (Dolado-Jenkins): solo constante y, posteriormente, sin constante ni tendencia. En todas las configuraciones se confirmó la presencia de raíz unitaria.

Con base en ello, se aplicó la primera diferencia a \ln_cred , obteniéndose la serie $d\ln_cred$ (ver Anexo 5 y 6). Esta nueva serie muestra un comportamiento más estable y sin tendencia, sugiriendo estacionariedad. El correlograma de $d\ln_cred$ presenta una caída progresiva en la FAS y picos iniciales en la FAP, patrón compatible con un proceso autorregresivo. En conclusión, la serie original \ln_cred es no estacionaria y altamente persistente. Por su alta persistencia, crecimiento sostenido y bajo nivel de volatilidad, la serie es consistente con un crédito hipotecario. Este tipo de crédito responde a decisiones de largo plazo y tiende a crecer de forma estable, a diferencia del crédito de consumo o MYPE, que suelen ser más volátiles. Esta interpretación es coherente con lo señalado por el Banco Central de Reserva del Perú (BCRP, Informe de Inflación, 2022), donde se indica que el crédito hipotecario presenta una evolución más estable y con menor sensibilidad a shocks de corto plazo. Luego de su transformación y modelado, se determinó que la dinámica mensual del crédito puede capturarse adecuadamente mediante un modelo AR estacionario.

II. Análisis de estacionariedad de las ventas logarítmicas: evaluación crediticia empresarial

La serie \ln_ventas presenta una clara tendencia creciente desde 1998, con un cambio de pendiente alrededor de 2009 y una caída puntual en 2020, probablemente asociada a la pandemia. No muestra reversión a una media constante, lo que sugiere que no es estacionaria en media. El correlograma confirma este diagnóstico: las autocorrelaciones son persistentemente altas y decrecen muy lentamente, evidenciando una fuerte inercia temporal típica de una serie con raíz unitaria. Esto indica que debe ser transformada antes de su modelación o proyección (ver Anexo 7 y 8).

Se evaluó la existencia de raíz unitaria en la serie \ln_ventas mediante la prueba de Dickey-Fuller Aumentada (ADF), siguiendo el procedimiento metodológico de Dolado, Jenkinson y Sosvilla-Rivero (1990) (ver Anexo 9, 10 y 11). Esta metodología sugiere partir del modelo más general (con constante y tendencia) e ir simplificando la especificación en función de la significancia de los coeficientes.

En las tres versiones del test (con constante y tendencia, solo constante y sin constante ni tendencia), el estadístico ADF no fue suficientemente negativo para rechazar la hipótesis nula de raíz unitaria, lo que sugiere que la serie no es estacionaria. Además, ni la constante ni la tendencia fueron estadísticamente significativas, lo que respalda el uso de la especificación más parsimoniosa. Aunque la mayoría de los tests, incluyendo el ADF con constante y tendencia, sugieren la presencia de una raíz unitaria, la regresión sin términos determinísticos muestra un coeficiente autorregresivo estadísticamente significativo. No obstante, dado que los valores críticos del test Dickey-Fuller no coinciden con los de una distribución t convencional, este resultado debe ser interpretado con cautela. La aparente contradicción no invalida los resultados, pero sugiere que el proceso podría ser estacionario en torno a cero, y que podría haber factores externos en el test, como quiebres estructurales. La significancia del coeficiente en el modelo más parsimonioso aumenta el poder de la prueba, pero también puede estar afectada por problemas de especificación o por quiebres estructurales no considerados explícitamente. Por esta razón, se recomienda complementar el análisis con pruebas que incorporen quiebres estructurales endógenos, como la prueba de Zivot y Andrews, a fin de obtener un diagnóstico más robusto. Una vez que se incorporan quiebres estructurales al análisis, el resultado de raíz unitaria se modifica sustancialmente. Inicialmente, al aplicar las pruebas convencionales de Dickey-Fuller Aumentada (ADF) y Phillips-Perron sobre la serie \ln_{ventas} , sin controlar por quiebres, no se rechaza la hipótesis nula de raíz unitaria. Esto sugería que la serie era no estacionaria, lo que implicaba una persistencia en los choques y una tendencia no constante a lo largo del tiempo. No obstante, esta conclusión cambia cuando se consideran posibles eventos estructurales que podrían haber alterado el comportamiento de la serie. Al aplicar la prueba de Zivot y Andrews (1992), la cual permite un único quiebre endógeno en la tendencia y/o intercepto, se identificaron dos fechas relevantes: agosto de 2009 y enero de 2020 (ver Anexo 12 y 13). La primera fecha se relaciona con los efectos rezagados de la crisis financiera global de 2008, que afectó la demanda externa y el crédito en el Perú, desacelerando el crecimiento económico (Morón & Castro, 2009; mientras que la segunda corresponde al inicio de la pandemia de COVID-19, que generó una fuerte contracción de la actividad económica debido a medidas de confinamiento y restricciones sanitarias (Banco Mundial, 2020).

Con base en esta información, se construyó un modelo que incorpora variables dicotómicas y términos de interacción (por ejemplo, $D1$, $D2$, trend_d1 , trend_d2) (ver anexo 15) para controlar por estos quiebres en nivel y pendiente. Al estimar la regresión bajo esta especificación, el resultado del test ADF cambia: se obtiene un estadístico de prueba de -3.35 (ver Anexo 16), que supera en valor absoluto al valor crítico de -2.57 , y un p -valor < 0.01 , lo que permite rechazar la hipótesis nula de raíz unitaria con alto nivel de confianza. Este resultado sugiere que la no estacionariedad observada inicialmente no era inherente a la serie, sino que estaba inducida por cambios estructurales no modelados. Por tanto, al controlar adecuadamente estos eventos, se obtiene evidencia de que la serie es estacionaria. El residuo de esta regresión, denominado residuo_limpio , fue analizado con el objetivo de encontrar un modelo ARMA adecuado que capture su dinámica. Se estimaron distintos modelos AR y ARMA (ver Anexo 17, 18, 19, 20, 21 y 22), y se compararon usando criterios de información (Akaike, Schwarz) y el análisis del correlograma de los errores.

El modelo óptimo seleccionado fue un $\text{ARMA}(1,1)$ (ver anexo 15), compuesto por un término autorregresivo de primer orden ($\text{AR}(1)$) y un término de media móvil de primer orden ($\text{MA}(1)$). Esta especificación resultó ser la más adecuada al presentar los menores valores en los criterios de

información de Akaike (-6.7352) y de Schwarz (-6.0855) en comparación con otras alternativas evaluadas. Los coeficientes estimados para los términos AR y MA fueron altamente significativos (p -valor < 0.01), lo que respalda estadísticamente la inclusión de ambos términos en el modelo. Finalmente, el correlograma de los residuos muestra una rápida caída de las funciones de autocorrelación (FAS) y autocorrelación parcial (FAP) dentro de los intervalos de confianza, y los p -valores asociados a la prueba de Ljung-Box (Q-Stat) superan el umbral de 0.05 para todos los rezagos considerados, lo que confirma que los errores del modelo se comportan como ruido blanco, es decir, son no correlacionados y aleatorios. En conjunto, esta evidencia indica que el modelo ARMA(1,1) sobre los residuos limpios representa adecuadamente la dinámica de la serie una vez controlada por no estacionariedad y quiebres estructurales

III. Diferencias entre las pruebas ADF y PP en un proceso AR(1)

Con el fin de entender cómo afecta un coeficiente de autocorrelación cercano a 1 a la estacionariedad de una serie, es necesario partir de la serie más básica, el modelo autorregresivo de orden 1; en otras palabras, de una AR(1). Queriendo analizar cómo afectan cambios en el coeficiente sobre la estacionariedad, se crearán tres procesos autorregresivos diferentes: el primero, con un coeficiente de 0.5; el segundo, de 0.85, y el tercero, de 0.994 (Ver el Anexo 20). Los gráficos vinculados a estas ecuaciones se pueden encontrar en los Anexos 23, 24 y 25. Es claro que la estacionariedad se reduce conforme aumenta el coeficiente asociado a y_{t-1} , lo que implica una pérdida de memoria de corto plazo y una tendencia a alejarse persistentemente de su media (la cual en este caso es 0). Este tipo de comportamiento está estrechamente vinculado con los problemas de raíz unitaria, pues un coeficiente cercano a 1 sugiere no estacionariedad y dificulta la predicción y el análisis econométrico confiable.

Es notorio que, para valores muy distintos de 1, los tests arrojan los mismos resultados: no hay existencia de raíz unitaria. No obstante, en la tercera serie, y como habría de esperarse de pruebas con metodologías distintas, a un nivel de 95% de confiabilidad, el test de DF rechaza la existencia de raíz (un p -value aproximado de 0.0381), pero el test de PP la acepta (con un p -value aproximado de 0.0540). Véanse los Anexos 26 y 27 para ver los datos estadísticos completos.

¿A qué se debe esta diferencia en los errores de predicción? Primero, es necesario explicar cada test. El test ADF se basa en dos supuestos: que se tiene un proceso AR(p) y que los errores no están correlacionados. Trata de controlar la correlación de los errores agregando rezagos. Si bien esto puede ser útil, en casos en los que existe correlación de los errores (como un ARMA), puede aumentar la varianza del estimador y dificultar el rechazo de la hipótesis nula incluso cuando la serie ya es casi estacionaria; en otras palabras, disminuye la potencia de prueba y aumenta el error de tipo 2 (Hamilton, 1997; Ng & Perron, 2001). El test PP no exige supuestos tan exigentes: los errores pueden ser dependientes y heterogéneamente distribuidos. No incluye rezagos, sino que corrige directamente los errores estándar usando métodos no paramétricos tipo Newey-West. Esto le permite lidiar mejor con problemas de autocorrelación y heterogeneidad sin modificar la estructura de la regresión, lo que en algunos casos le da más robustez que el ADF. Sin embargo, esa misma corrección puede hacer que el PP sea más conservador: al inflar el error estándar, el estadístico de prueba disminuye y es menos probable que se rechace la raíz unitaria en casos donde tales problemas (endogeneidad y heterogeneidad) no ocurran; en otras palabras, se pierde potencia de prueba y, por tanto, se aumenta el error tipo 2 (Hamilton, 1997; Ng & Perron, 2001). Los estimadores también son distintos. Véase

el Anexo 29. La prueba idónea será la ADF, debido a que los errores en un AR son ruido blanco que ni explícita ni implícitamente dependen de sus pasados, de modo que no hay problemas de correlación entre ellos. Esta es la razón por la que un modelo PP pierde potencia de prueba. Es el ADF el mejor.

IV. Diferencias entre las pruebas ADF y PP en un proceso ARMA(1,1)

La respuesta final, no obstante, no acaba aquí, debido a que es necesario preguntarse acerca de otros modelos no necesariamente estacionarios, como los ARMA(p,q). El proceso generador de datos de este modelo puede verse en el Anexo 30. Observando el gráfico, ubicado en el Anexo 28, vemos que es difícil determinar la estacionariedad. Ello, debido a que los datos no convergen rápidamente a un mismo valor (en este caso, el inicial, 0), sino que son más volátiles.

Como se mencionó anteriormente, detectar la estacionariedad en este caso es difícil. Las diferencias en los resultados entre ambos tests guardan la misma causa que en el caso anterior: los disímiles supuestos formativos. Ello puede verse en que el test ADF acepta la existencia de raíz unitaria, pero el test PP la acepta. Ambos tests pueden verse en los Anexos 31 y 32, respectivamente.

¿A qué se debe esta diferencia? Como se mencionó anteriormente, la forma en la que los tests miden si hay raíz unitaria. Debido a que en un modelo ARMA los errores dependen implícitamente de sus pasados (pues un y_t tiene un ε_t y un ε_{t-1}), entonces el aumento de rezagos no podrá controlar los problemas de autocorrelación que tengan sus nuevos errores, mientras que una prueba PP sí, pues esta corrige por heterocedasticidad y por autocorrelación. Así, la prueba idónea será la no paramétrica por sus características metodológicas.

V. Detección de raíz unitaria en una serie con quiebres: ADF y ZA


En caso de un quiebre estructural, ¿cómo se detecta la raíz unitaria? Esa pregunta es interesante. Para observar aquello, se generará una serie estacionaria con quiebre estructural. La estructura puede verse en el Anexo 33. El gráfico asimismo puede observarse en el Anexo 34. El quiebre puede observarse en el cambio de media (de 0 a 8¹).

Los tests de Dickey-Fuller y de Zivot-Andrews ofrecen perspectivas interesantes. Por un lado, el test ADF menciona que hay una raíz unitaria, pese a que los procesos son estacionarios en diferentes tiempos (antes de 300 y después de 300). En el caso del test Zivot-Andrews, menciona meramente que hay un quiebre a partir de 300, como estaba previsto. Los resultados pueden verse en los Anexos 35 y 36. ¿Por qué se produce esta diferencia? Porque el test ADF (y otros tests) asumen que la dinámica del proceso es estable en todo el periodo, sin rupturas. Si hay un cambio abrupto en el intercepto (como en el período 300), ese salto se interpreta erróneamente como un shock aleatorio persistente (o una tendencia estocástica persistente), lo cual sesga la prueba hacia la no estacionariedad. Esta mala praxis genera que se elimine información valiosa de largo plazo, afecta la estimación (pues la corrección de la raíz unitaria no contempla la implementación de una dummy variable según el período, sino una diferenciación) y, por tanto, se distorsiona la inferencia. La diferencia entre el estimador t y el estimador ADF sugiere la presencia de quiebres estructurales, lo que se deberá investigar con Solado-Jenkins.

¹ Es necesario recordar que, como el cambio en el drift es de 4 (de 0 a 4), entonces en el largo plazo, el cambio será de 4 entre 0.5.

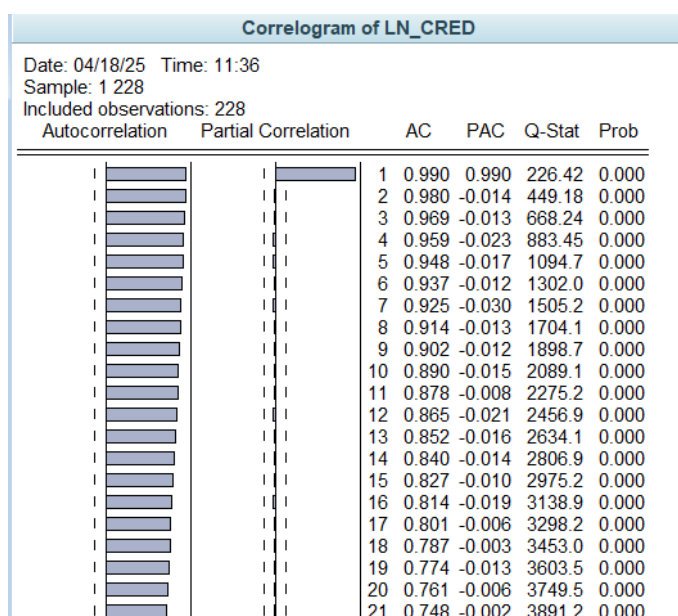
Anexo 1

Serie del logaritmo de los créditos



Anexo 2

Correlograma del logaritmo de los créditos



Anexo 3

Prueba ADF al ln_cred para un modelo con constante y tendencia

Augmented Dickey-Fuller Unit Root Test on LN_CRED				
Null Hypothesis: LN_CRED has a unit root				
Exogenous: Constant, Linear Trend				
Lag Length: 5 (Fixed)				
			t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic			-1.141468	0.9186
Test critical values:	1% level		-3.999930	
	5% level		-3.430196	
	10% level		-3.138663	
*MacKinnon (1996) one-sided p-values.				
Augmented Dickey-Fuller Test Equation				
Dependent Variable: D(LN_CRED)				
Method: Least Squares				
Date: 04/18/25 Time: 12:18				
Sample (adjusted): 7 228				
Included observations: 222 after adjustments				
Variable	Coefficient	Std. Error	t-Statistic	Prob.
LN_CRED(-1)	-0.006542	0.005731	-1.141468	0.2550
D(LN_CRED(-1))	0.005114	0.068042	0.075162	0.9402
D(LN_CRED(-2))	0.129946	0.067152	1.935115	0.0543
D(LN_CRED(-3))	0.298396	0.063635	4.689211	0.0000
D(LN_CRED(-4))	0.136301	0.066170	2.059847	0.0406
D(LN_CRED(-5))	0.064925	0.066810	0.971779	0.3323
C	0.060916	0.047223	1.289977	0.1985
@TREND("1")	7.89E-05	8.37E-05	0.943639	0.3464
R-squared	0.208890	Mean dependent var		0.013003
Adjusted R-squared	0.183013	S.D. dependent var		0.013250
S.E. of regression	0.011976	Akaike info criterion		-5.976443
Sum squared resid	0.030693	Schwarz criterion		-5.853824
Log likelihood	671.3852	Hannan-Quinn criter.		-5.926937
F-statistic	8.072288	Durbin-Watson stat		1.966948
Prob(F-statistic)	0.000000			


Anexo 4

Prueba PP al ln_cred para un modelo con constante y tendencia

Phillips-Perron Unit Root Test on LN_CRED		
Null Hypothesis: LN_CRED has a unit root		
Exogenous: Constant, Linear Trend		
Bandwidth: 4 (Used-specified) using Bartlett kernel		
	Adj. t-Stat	Prob.*
Phillips-Perron test statistic	-0.583137	0.9788
Test critical values: 1% level	-3.998997	
5% level	-3.429745	
10% level	-3.138397	
*MacKinnon (1996) one-sided p-values.		
Residual variance (no correction)		0.000183
HAC corrected variance (Bartlett kernel)		0.000380
Phillips-Perron Test Equation		
Dependent Variable: D(LN_CRED)		
Method: Least Squares		
Date: 04/18/25 Time: 12:21		
Sample (adjusted): 2 228		
Included observations: 227 after adjustments		

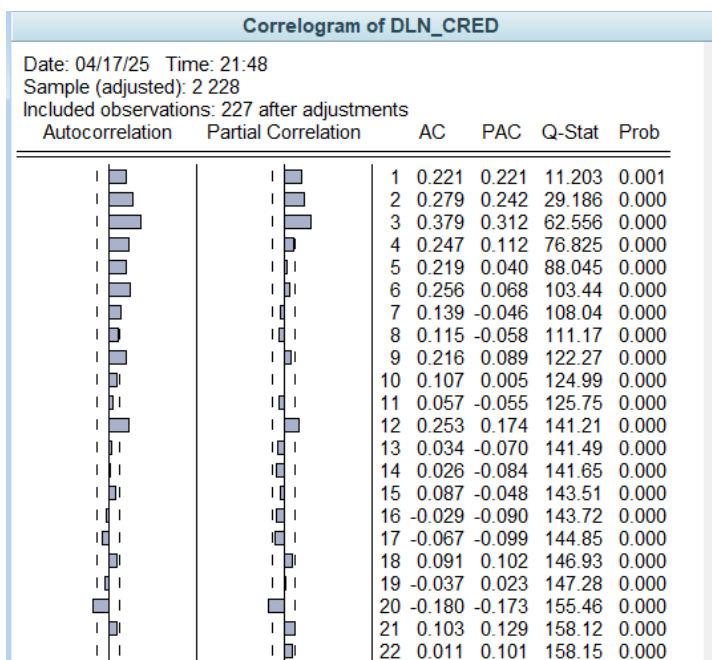
Anexo 5

Serie diferenciada del logaritmo de los créditos




Anexo 6

Correlograma al ln_cred diferenciado




Anexo 7

Serie del logaritmo de las ventas



Anexo 8

Correlograma del logaritmo de las ventas



Anexo 9

Prueba ADF al ln_ventas para un modelo con constante y tendencia

Augmented Dickey-Fuller Unit Root Test on LN_VENTAS		
Null Hypothesis: LN_VENTAS has a unit root		
Exogenous: Constant, Linear Trend		
Lag Length: 5 (Fixed)		
	t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic	-1.367315	0.8687
Test critical values: 1% level	-3.987180	
5% level	-3.424019	
10% level	-3.135019	

*MacKinnon (1996) one-sided p-values.

Augmented Dickey-Fuller Test Equation
 Dependent Variable: D(LN_VENTAS)
 Method: Least Squares
 Date: 04/18/25 Time: 16:00
 Sample (adjusted): 1998M07 2024M12
 Included observations: 318 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
LN_VENTAS(-1)	-0.005943	0.004347	-1.367315	0.1725
D(LN_VENTAS(-1))	-0.051273	0.056502	-0.907447	0.3649
D(LN_VENTAS(-2))	0.014574	0.056079	0.259889	0.7951
D(LN_VENTAS(-3))	0.282623	0.053590	5.273824	0.0000
D(LN_VENTAS(-4))	0.129227	0.055856	2.313561	0.0213
D(LN_VENTAS(-5))	0.031225	0.056209	0.555508	0.5789
C	0.033432	0.023169	1.442947	0.1500
@TREND("1998M01")	2.73E-05	1.96E-05	1.389846	0.1656
R-squared	0.101335	Mean dependent var	0.003351	
Adjusted R-squared	0.081043	S.D. dependent var	0.008619	
S.E. of regression	0.008262	Akaike info criterion	-6.729440	
Sum squared resid	0.021161	Schwarz criterion	-6.634798	
Log likelihood	1077.981	Hannan-Quinn criter.	-6.691640	
F-statistic	4.993743	Durbin-Watson stat	1.987450	
Prob(F-statistic)	0.000022			

Anexo 10

Prueba ADF al ln_ventas para un modelo con constante

Augmented Dickey-Fuller Unit Root Test on LN_VENTAS

Null Hypothesis: LN_VENTAS has a unit root
 Exogenous: Constant
 Lag Length: 5 (Fixed)

	t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic	-0.094779	0.9477
Test critical values: 1% level	-3.450747	
5% level	-2.870416	
10% level	-2.571569	

*MacKinnon (1996) one-sided p-values.

Augmented Dickey-Fuller Test Equation

Dependent Variable: D(LN_VENTAS)

Method: Least Squares

Date: 04/18/25 Time: 16:01

Sample (adjusted): 1998M07 2024M12

Included observations: 318 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
LN_VENTAS(-1)	-0.000106	0.001123	-0.094779	0.9246
D(LN_VENTAS(-1))	-0.051394	0.056587	-0.908231	0.3645
D(LN_VENTAS(-2))	0.014977	0.056162	0.266673	0.7899
D(LN_VENTAS(-3))	0.282782	0.053670	5.268920	0.0000
D(LN_VENTAS(-4))	0.127100	0.055919	2.272926	0.0237
D(LN_VENTAS(-5))	0.028931	0.056269	0.514150	0.6075
C	0.002638	0.006786	0.388762	0.6977
R-squared	0.095735	Mean dependent var	0.003351	
Adjusted R-squared	0.078290	S.D. dependent var	0.008619	
S.E. of regression	0.008274	Akaike info criterion	-6.729518	
Sum squared resid	0.021293	Schwarz criterion	-6.646705	
Log likelihood	1076.993	Hannan-Quinn criter.	-6.696442	
F-statistic	5.487649	Durbin-Watson stat	1.986086	
Prob(F-statistic)	0.000020			

Anexo 11

Prueba ADF al ln_ventas para un modelo sin constante ni tendencia

Augmented Dickey-Fuller Unit Root Test on LN_VENTAS

Null Hypothesis: LN_VENTAS has a unit root

Exogenous: None

Lag Length: 5 (Fixed)

	t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic	3.373828	0.9998
Test critical values:		
1% level	-2.572254	
5% level	-1.941824	
10% level	-1.616032	

*MacKinnon (1996) one-sided p-values.

Augmented Dickey-Fuller Test Equation
 Dependent Variable: D(LN_VENTAS)
 Method: Least Squares
 Date: 04/18/25 Time: 16:02
 Sample (adjusted): 1998M07 2024M12
 Included observations: 318 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
LN_VENTAS(-1)	0.000328	9.73E-05	3.373828	0.0008
D(LN_VENTAS(-1))	-0.051295	0.056509	-0.907729	0.3647
D(LN_VENTAS(-2))	0.014952	0.056086	0.266595	0.7900
D(LN_VENTAS(-3))	0.282519	0.053593	5.271607	0.0000
D(LN_VENTAS(-4))	0.126785	0.055837	2.270634	0.0239
D(LN_VENTAS(-5))	0.028493	0.056181	0.507170	0.6124
R-squared	0.095296	Mean dependent var		0.003351
Adjusted R-squared	0.080798	S.D. dependent var		0.008619
S.E. of regression	0.008263	Akaike info criterion		-6.735321
Sum squared resid	0.021304	Schwarz criterion		-6.664339
Log likelihood	1076.916	Hannan-Quinn criter.		-6.706971
Durbin-Watson stat	1.986100			

Anexo 12

Prueba Z&A al ln_ventas para un modelo con tendencia e intercepto

Unit Root with Break Test on LN_VENTAS		
Null Hypothesis: LN_VENTAS has a unit root		
Trend Specification: Trend and intercept		
Break Specification: Trend and intercept		
Break Type: Innovational outlier		
Break Date: 2009M08		
Break Selection: Minimize Dickey-Fuller t-statistic		
Lag Length: 2 (Automatic - based on Schwarz information criterion, maxlag=16)		
	t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic	-3.707933	0.7025
Test critical values: 1% level	-5.719131	
5% level	-5.175710	
10% level	-4.893950	
*Vogelsang (1993) asymptotic one-sided p-values.		

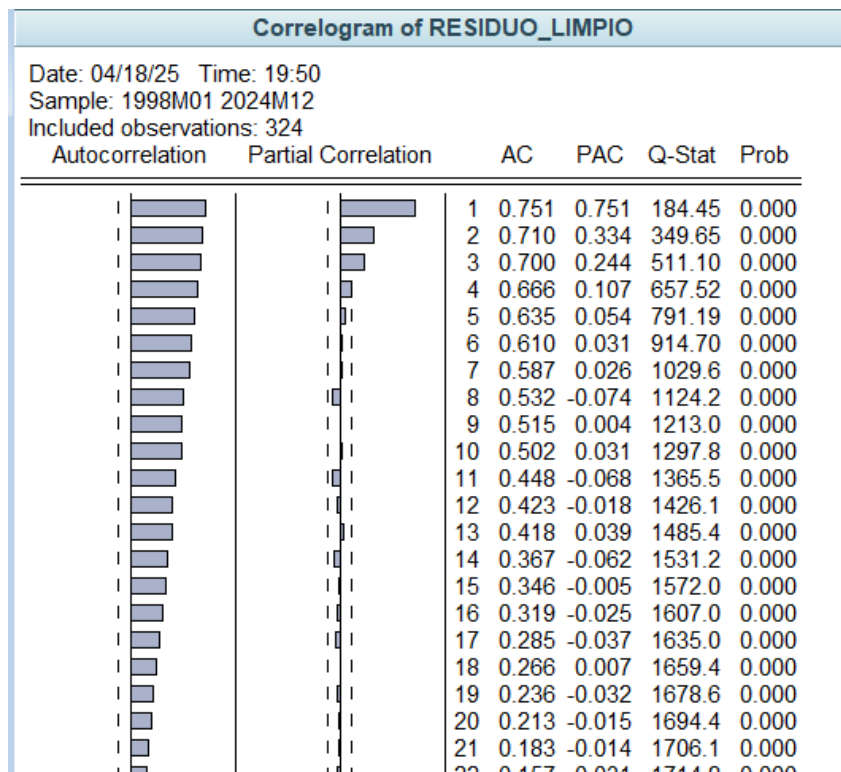
Anexo 13

Prueba Z&A al ln_ventas para un modelo con tendencia e intercepto

Unit Root with Break Test on LN_VENTAS		
Null Hypothesis: LN_VENTAS has a unit root		
Trend Specification: Trend and intercept		
Break Specification: Trend and intercept		
Break Type: Innovational outlier		
Break Date: 2020M01		
Break Selection: Minimize Dickey-Fuller t-statistic		
Lag Length: 13 (Automatic - based on Schwarz information criterion, maxlag=13)		
	t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic	-7.673729	< 0.01
Test critical values: 1% level	-5.719131	
5% level	-5.175710	
10% level	-4.893950	
*Vogelsang (1993) asymptotic one-sided p-values.		
Augmented Dickey-Fuller Test Equation		
Dependent Variable: LN_VENTAS		
Method: Least Squares		
Date: 04/18/25 Time: 16:51		
Sample: 2010M01 2024M12		
Included observations: 180		

Anexo 14

Correlograma de los residuos limpios



Anexo 15

Ecuación estimada con las variables dicotómicas correspondientes y ecuación ARMA

$$\text{Ln_ventastt} = \alpha + \beta \cdot \text{trendt} + \gamma_1 \cdot \text{D1t} + \gamma_2 \cdot \text{trend_D1t} + \gamma_3 \cdot \text{D2t} + \gamma_4 \cdot \text{trend_D2t} + \varepsilon_t$$

$$\text{RESIDUO_LIMPIOt} = 0.9552 \cdot \text{RESIDUO_LIMPIOt-1} - 0.5793 \cdot \varepsilon_{t-1} + \varepsilon_t$$

Anexo 16

Prueba ADF sobre los residuos limpios

Augmented Dickey-Fuller Unit Root Test on RESIDUO_LIMPIO		
Null Hypothesis: RESIDUO_LIMPIO has a unit root		
Exogenous: None		
Lag Length: 2 (Automatic - based on SIC, maxlag=16)		
	t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic	-3.357103	0.0008
Test critical values: 1% level	-2.572186	
5% level	-1.941814	
10% level	-1.616038	
*MacKinnon (1996) one-sided p-values.		

Anexo 17

Modelo AR(1)

Dependent Variable: RESIDUO_LIMPIO
Method: ARMA Maximum Likelihood (OPG - BHHH)
Date: 04/18/25 Time: 20:24
Sample: 1998M01 2024M12
Included observations: 324
Convergence achieved after 50 iterations
Coefficient covariance computed using outer product of gradients

Variable	Coefficient	Std. Error	t-Statistic	Prob.
AR(1)	0.748831	0.018409	40.67650	0.0000
SIGMASQ	0.000156	2.26E-06	69.24601	0.0000
R-squared	0.564116	Mean dependent var	-6.77E-16	
Adjusted R-squared	0.562762	S.D. dependent var	0.018971	
S.E. of regression	0.012544	Akaike info criterion	-5.910423	
Sum squared resid	0.050669	Schwarz criterion	-5.887085	
Log likelihood	959.4885	Hannan-Quinn criter.	-5.901108	
Durbin-Watson stat	2.496019			
Inverted AR Roots	.75			

Anexo 18

Modelo AR(2)

Dependent Variable: RESIDUO_LIMPIO				
Method: ARMA Maximum Likelihood (OPG - BHHH)				
Date: 04/18/25 Time: 20:26				
Sample: 1998M01 2024M12				
Included observations: 324				
Convergence achieved after 46 iterations				
Coefficient covariance computed using outer product of gradients				
Variable	Coefficient	Std. Error	t-Statistic	Prob.
AR(2)	0.705912	0.019863	35.53918	0.0000
SIGMASQ	0.000178	2.87E-06	61.90816	0.0000
R-squared	0.504001	Mean dependent var	-6.77E-16	
Adjusted R-squared	0.502460	S.D. dependent var	0.018971	
S.E. of regression	0.013381	Akaike info criterion	-5.779506	
Sum squared resid	0.057657	Schwarz criterion	-5.756168	
Log likelihood	938.2800	Hannan-Quinn criter.	-5.770191	
Durbin-Watson stat	1.593973			
Inverted AR Roots	.84	-.84		

Anexo 19

Modelo AR(3)

Dependent Variable: RESIDUO_LIMPIO				
Method: ARMA Maximum Likelihood (OPG - BHHH)				
Date: 04/18/25 Time: 20:24				
Sample: 1998M01 2024M12				
Included observations: 324				
Convergence achieved after 51 iterations				
Coefficient covariance computed using outer product of gradients				
Variable	Coefficient	Std. Error	t-Statistic	Prob.
AR(3)	0.694947	0.019156	36.27835	0.0000
SIGMASQ	0.000183	3.03E-06	60.20539	0.0000
R-squared	0.491194	Mean dependent var	-6.77E-16	
Adjusted R-squared	0.489614	S.D. dependent var	0.018971	
S.E. of regression	0.013553	Akaike info criterion	-5.752164	
Sum squared resid	0.059146	Schwarz criterion	-5.728826	
Log likelihood	933.8505	Hannan-Quinn criter.	-5.742848	
Durbin-Watson stat	1.379958			
Inverted AR Roots	.89	-.44-.77i	-.44+.77i	

Anexo 20

Modelo AR(4)

Dependent Variable: RESIDUO_LIMPIO				
Method: ARMA Maximum Likelihood (OPG - BHHH)				
Date: 04/18/25 Time: 20:26				
Sample: 1998M01 2024M12				
Included observations: 324				
Convergence achieved after 41 iterations				
Coefficient covariance computed using outer product of gradients				
Variable	Coefficient	Std. Error	t-Statistic	Prob.
AR(4)	0.658829	0.021643	30.44029	0.0000
SIGMASQ	0.000199	3.60E-06	55.43532	0.0000
R-squared	0.444063	Mean dependent var	-6.77E-16	
Adjusted R-squared	0.442336	S.D. dependent var	0.018971	
S.E. of regression	0.014167	Akaike info criterion	-5.662655	
Sum squared resid	0.064624	Schwarz criterion	-5.639317	
Log likelihood	919.3502	Hannan-Quinn criter.	-5.653340	
Durbin-Watson stat	1.291356			
Inverted AR Roots	.90	-.00+.90i	-.00-.90i	-.90

Anexo 21

Modelo ARMA(1,1)

Equation: UNTITLED Workfile: VENTAS::Ventas\				
View	Proc	Object	Print	Name Freeze Estimate Forecast Stats Resids
Dependent Variable: RESIDUO_LIMPIO				
Method: ARMA Maximum Likelihood (OPG - BHHH)				
Date: 04/18/25 Time: 20:29				
Sample: 1998M01 2024M12				
Included observations: 324				
Convergence achieved after 35 iterations				
Coefficient covariance computed using outer product of gradients				
Variable	Coefficient	Std. Error	t-Statistic	Prob.
AR(1)	0.955242	0.015239	62.68224	0.0000
MA(1)	-0.573933	0.063583	-9.026468	0.0000
SIGMASQ	0.000129	1.75E-06	73.85977	0.0000
R-squared	0.639746	Mean dependent var	-6.77E-16	
Adjusted R-squared	0.637502	S.D. dependent var	0.018971	
S.E. of regression	0.011422	Akaike info criterion	-6.093511	
Sum squared resid	0.041877	Schwarz criterion	-6.058504	
Log likelihood	990.1488	Hannan-Quinn criter.	-6.079538	
Durbin-Watson stat	1.993008			
Inverted AR Roots	.96			
Inverted MA Roots	.57			

Anexo 22

Correlograma de los residuos del modelo ARMA(1,1)

Correlogram of Residuals						
Date: 04/18/25 Time: 20:39						
Sample: 1998M01 2024M12						
Q-statistic probabilities adjusted for 2 ARMA terms						
Autocorrelation	Partial Correlation	AC	PAC	Q-Stat	Prob	
1	0.003	0.003	0.0038			
2	-0.040	-0.040	0.5376			
3	0.044	0.045	1.1891	0.276		
4	0.020	0.018	1.3270	0.515		
5	0.014	0.017	1.3884	0.708		
6	0.028	0.028	1.6545	0.799		
7	0.061	0.060	2.8765	0.719		
8	-0.046	-0.046	3.5718	0.734		
9	0.005	0.007	3.5788	0.827		
10	0.073	0.063	5.3527	0.719		
11	-0.035	-0.035	5.7659	0.763		
12	-0.019	-0.015	5.8856	0.825		
13	0.074	0.066	7.7681	0.734		
14	-0.022	-0.026	7.9374	0.790		
15	0.008	0.019	7.9570	0.846		
16	0.014	0.003	8.0216	0.888		
17	-0.016	-0.022	8.1129	0.919		
18	0.014	0.023	8.1783	0.943		
19	-0.003	-0.010	8.1819	0.963		
20	0.013	0.002	8.2411	0.975		

Anexo 23

Regresiones AR(1) estimadas según distintos valores del coeficiente asociado al rezago


$$y_t = 0.5 * y_{t-1} + \varepsilon_t$$

$$y_t = 0.85 * y_{t-1} + \varepsilon_t$$

$$y_t = 0.994 * y_{t-1} + \varepsilon_t$$


Anexo 24

Gráfico de la primera regresión AR(1)




Anexo 25

Gráfico de la segunda regresión AR(1)



Anexo 26

Gráfico de la tercera regresión AR(1)



Anexo 27

Pruebas de Dickey-Fuller para las series AR, según el coeficiente asociado al primer rezago

Prueba de Dickey-Fuller para la primera serie (coeficiente de 0.5)

	Test statistic	Dickey-Fuller critical value		
		1%	5%	10%
Z(t)	-6.954	-3.430	-2.860	-2.570

MacKinnon approximate *p*-value for Z(t) = 0.0000.

Prueba de Dickey-Fuller para la segunda serie (coeficiente de 0.85)

	Test statistic	Dickey-Fuller critical value		
		1%	5%	10%
Z(t)	-5.446	-3.430	-2.860	-2.570

MacKinnon approximate *p*-value for Z(t) = 0.0000.

Prueba de Dickey-Fuller (DF) para la tercera serie (coeficiente de 0.994)

	Test statistic	Dickey-Fuller critical value		
		1%	5%	10%
Z(t)	-2.967	-3.430	-2.860	-2.570

MacKinnon approximate *p*-value for Z(t) = 0.0381.

Anexo 28

Pruebas de Phillips-Perron para las series AR, según el coeficiente asociado al primer rezago

Prueba de Phillips-Perron (PP) para la primera serie (coeficiente de 0.5)

	Test statistic	Dickey-Fuller critical value		
		1%	5%	10%
Z(rho)	-524.887	-20.700	-14.100	-11.300
Z(t)	-18.332	-3.430	-2.860	-2.570

MacKinnon approximate p -value for Z(t) = **0.0000**.

Prueba de Phillips-Perron (PP) para la segunda serie (coeficiente de 0.85)

	Test statistic	Dickey-Fuller critical value		
		1%	5%	10%
Z(rho)	-180.172	-20.700	-14.100	-11.300
Z(t)	-9.877	-3.430	-2.860	-2.570

MacKinnon approximate p -value for Z(t) = **0.0000**.

Prueba de Phillips-Perron (PP) para la tercera serie (coeficiente de 0.994)

	Test statistic	Dickey-Fuller critical value		
		1%	5%	10%
Z(rho)	-16.687	-20.700	-14.100	-11.300
Z(t)	-2.831	-3.430	-2.860	-2.570

MacKinnon approximate p -value for Z(t) = **0.0540**.

Anexo 29

Estadísticos para el test ADF y PP

Estadístico del test ADF

$$t_{adf} = \frac{\delta_{estimado}}{SE_{estimado}}$$

Estadístico del test PP

$$t_{pp} = \frac{\gamma_o^{1/2} t_\theta}{\varpi} - \frac{(\varpi^2 - \gamma_o) T s_\theta}{2\varpi\sigma}, \text{ donde}$$

γ_o : Varianza estimada de los errores

t_θ : Estadístico t convencional de la regresión $\Delta y_t = \alpha + \theta y_{t-1} + \varepsilon$

$\hat{\omega}^2$: Estimación HAC (Heteroskedasticity and Autocorrelation Consistent) de la varianza del error; por ejemplo, con el estimador de Newey-West

T : Número de observaciones

s_θ : Error estándar no corregido del estimador θ

σ : Desviación estándar de los errores estimada por MCO

Nótese que, a diferencia del test ADF, este test es de dos periodos: es decir, primero se estima t_θ y luego se corrige.

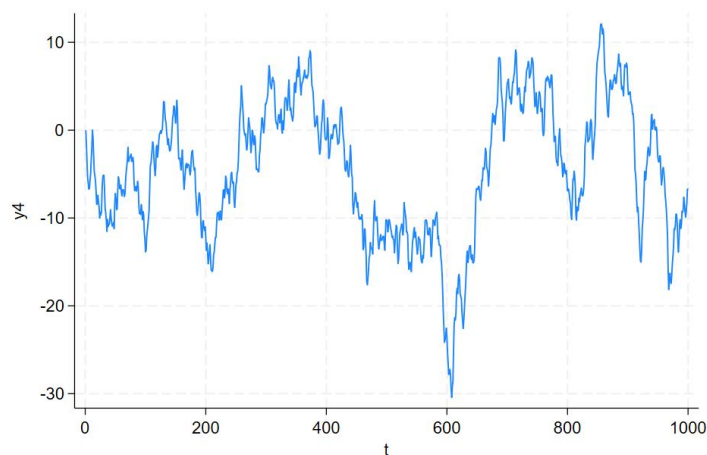
Anexo 30

Regresión ARMA(1,1) estimada con un coeficiente de 0.995 adscrito a la parte AR y de 0.5, a la parte MA

$$y_t = 0.995 * y_{t-1} + \varepsilon_t - 0.5 * \varepsilon_{t-1}$$

Anexo 31

Gráfico de la serie ARMA(1,1)



Nótese que, a simple vista, no puede afirmarse si es o no estacionaria.

Anexo 32

Test ADF para el modelo ARMA(1,1) planteado

	Test statistic	Dickey-Fuller critical value		
		1%	5%	10%
Z(t)	-2.857	-3.430	-2.860	-2.570

MacKinnon approximate *p*-value for Z(t) = **0.0506**.

Test PP para el modelo ARMA(1,1) planteado

	Test statistic	Dickey-Fuller critical value		
		1%	5%	10%
Z(rho)	-16.993	-20.700	-14.100	-11.300
Z(t)	-2.930	-3.430	-2.860	-2.570

MacKinnon approximate *p*-value for Z(t) = **0.0419**.

Nótese la diferencia en la aceptación de raíz unitaria de ambos tests. Debido a que el modelo presenta correlación entre errores en el tiempo (puesto que y_{t-1} tiene a ε_{t-1} , el cual está relacionado con ε_t y así), entonces la mejor prueba es la PP.

Anexo 33


Regresión AR(1) estimada con un coeficiente de 0.5 del rezago y un quiebre estructural T_b

$$y_t = 0.5 * y_{t-1} + \varepsilon_t + T_b$$

donde: T_b toma el valor de 0 si se está en la posición menor o igual a 300, y 1 de otro modo.

Anexo 34

Gráfico de la serie AR(1) con quiebre estructural en T=300



Anexo 35

Prueba ADF de la serie AR(1) con quiebre estructural

	Test statistic	Dickey-Fuller critical value		
		1%	5%	10%
Z(t)	-1.730	-3.430	-2.860	-2.570

Mackinnon approximate p -value for Z(t) = **0.4155**.

Anexo 36

Prueba Zivot-Andrews de la serie AR(1) con quiebre estructural

Zivot-Andrews unit root test for y5

Allowing for break in intercept

Lag selection via TTest: lags of D.y5 included = 5

Minimum t-statistic -13.860 at 300 (obs 300)

Critical values: 1%: -5.34 5%: -4.80 10%: -4.58

Referencias Bibliográficas

Banco Central de Reserva del Perú. (2025, enero 27). *Crédito hipotecario creció 5% en 2024*. [Nota informativa]. <https://www.bcrp.gob.pe/docs/Transparencia/Notas-Informativas/2025/nota-informativa-2025-01-27.pdf>Banco Central de Reserva del Perú+4

Banco Mundial. (2020, septiembre 8). *Crisis por el coronavirus aumentó las desigualdades en el Perú*. Recuperado de: https://www.bancomundial.org/es/news/press-release/2020/09/08/crisis-por-el-coronavirus-aumento-las-desigualdades-en-el-peru?utm_source

Hamilton, J. D. (1994). *Time series analysis*. Princeton University Press.

Moron, E. & Castro J. (2009). *The global crisis and the Peruvian labor market: impact and policy options*. <https://repositorio.up.edu.pe/backend/api/core/bitstreams/280fb5f3-2c25-4825-ad2e-14b039b320c4/content>

Ng, S., & Perron, P. (2001). Lag length selection and the construction of unit root tests with good size and power. *Econometrica*, 69(6), 1519–1554. <https://doi.org/10.1111/1468-0262.00256>